BTL11 · DATA MINING · 2026-10-27

Music Genre & Audio Track Segmentation

Phân cụm không giám sát trên Spotify Tracks Dataset — K-Means và GMM

114.000 dòng · 89.741 track duy nhất · 114 genre

Đồ án BTL11 · số liệu khóa 2026-10-27 · nguồn: artifacts/final-report-tables/

MÔ HÌNH CUỐI ĐƯỢC KHÓA

K = 2

K-Means · Robust F9

không PCA · seed 42

Silhouette (dev) 0,5956

Silhouette (holdout) 0,5902

Stability ARI 0,9997

89.741 track · 114 genre · 0 conflict

Bài toán & câu hỏi nghiên cứu

Phân cụm không giám sát: tìm cấu trúc âm học, không dự đoán genre

Bốn câu hỏi nghiên cứu

01 Dữ liệu âm học có cấu trúc cụm có ý nghĩa không?

02 K-Means (hard) và GMM (soft) khác nhau thế nào về phân đoạn và độ bất định?

03 K nào hợp lý khi xét validity, balance, stability, diễn giải và parsimony?

04 Các cụm có mô tả được "audio persona" mà không nhầm với genre không?

Genre, track_id và metadata không bao giờ vào X

Nếu dùng genre để chọn K, scaler hay model thì bài toán không còn unsupervised.

Phạm vi

TRONG PHẠM VI

Audit & dedup · split ID-disjoint · F5/F9 · Standard/Robust · PCA · K-Means · GMM · validity · stability · holdout · refit · profile · PCA2D/t-SNE · Ward · genre post-hoc

NGOÀI PHẠM VI

Supervised genre classification · recommender · Spotify API runtime · deep learning · dashboard · DBSCAN/Apriori bắt buộc

Không dùng accuracy; không tuyên bố dự đoán genre. P2 được deferred có chủ ý.

Dữ liệu & provenance

Đúng một snapshot Kaggle; đơn vị phân tích là track_id duy nhất, không phải dòng CSV

114.000
dòng CSV
20.118.244 bytes

89.741
track_id duy nhất
16.641 ID xuất hiện lặp

114
genre quan sát
16.299 track đa thể loại

0
vector xung đột
0 row bị quarantine

SPLIT ID-DISJOINT THEO HASH seed:track_id

71.813
Development
chọn model & ablation

68.813
Fit
scaler / PCA / clusterer

3.000
Eval cohort
nằm ngoài fit

17.928
Holdout
một lần, sau freeze

PROVENANCE & COMPLIANCE

Kaggle — maharshipandya/-spotify-tracks-dataset

SHA-256 b202fa49…177bd · 20.118.244 bytes

track_genres.parquet: 113.550 cặp (track_id, genre)

License: pending_human_verification

redistribution_allowed = false · raw CSV không public

ODbL 1.0 (Kaggle) vs BSD (HF mirror) vs Spotify provenance

Nguồn: artifacts/final-report-tables/dataset_summary.csv · data/processed/audit.json

EDA & không gian đặc trưng F9

Chín đặc trưng âm học; tương quan mạnh được ghi nhận thay vì che giấu

F9 — 9 đặc trưng âm học

Chỉ tín hiệu âm học; không genre, track_id hay metadata

danceability	energy	loudness
speechiness	acousticness	instrumentalness
liveness	valence	tempo

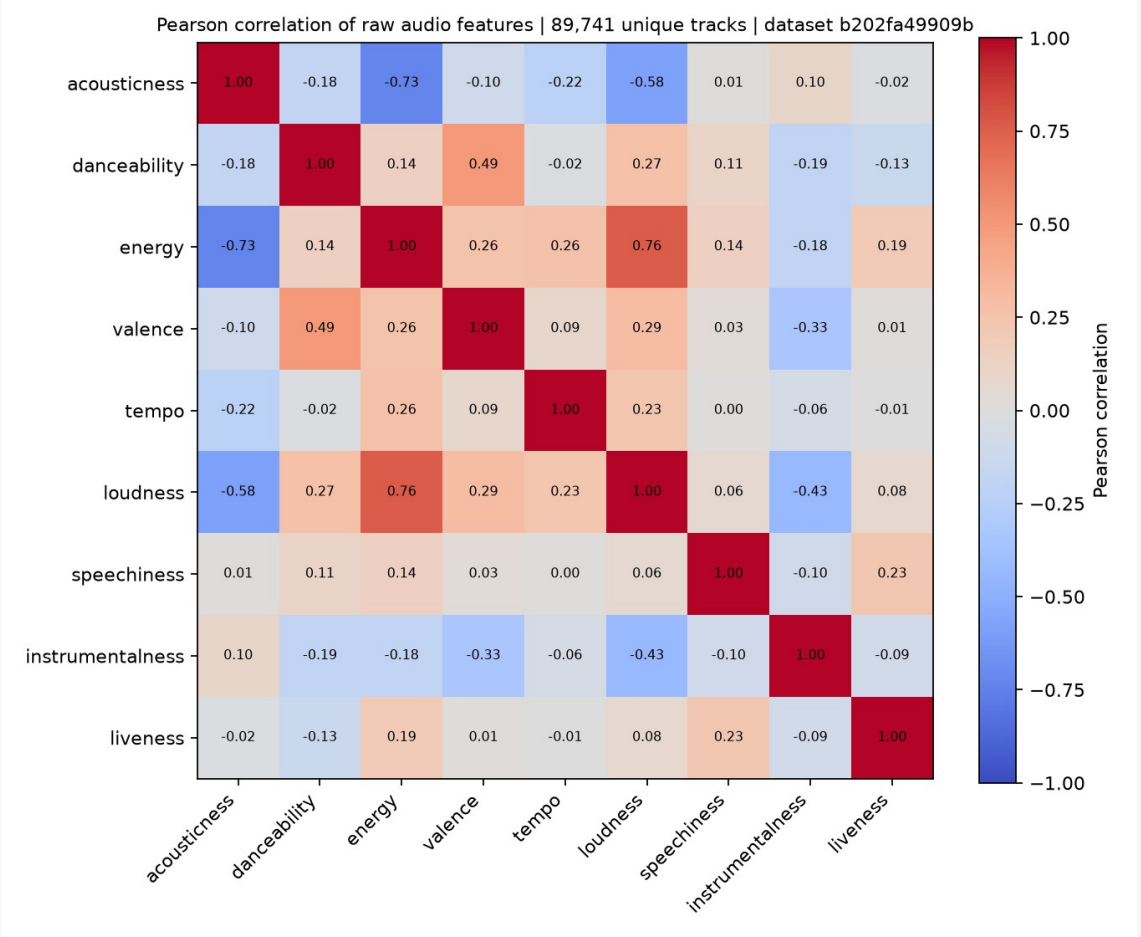
GIẢM CHIỀU

PCA90 · 7 components · 94,82% variance

PCA95 · 8 components · 98,44% variance

Final · no PCA: diễn giải trực tiếp

Đa cộng tuyến được ghi nhận. PCA không phải "95% accuracy"; đây chỉ là một representation thay thế.



Feature correlation — F9 trên 89.741 track

Pipeline & kiểm soát leakage

Một chiều từ raw CSV đến model khóa, holdout một lần và refit toàn bộ

1

Audit & dedup

114.000 dòng → 89.741 track; 0 ID conflict; 894 dòng trùng hoàn toàn

2

Split ID-disjoint

hash(seed:track_id); dev 71.813 / holdout 17.928

3

Fit-only transform

Scaler và PCA chỉ fit trên 68.813 fit IDs; eval/holdout chỉ transform

4

Eval cohort

3.000 track ngoài fit; chấm Silhouette / DB / CH

5

Freeze & holdout

Khóa model trước; holdout đúng một lần, không refit

6

Full refit

Fit 89.741 track; model identity riêng, không kế thừa holdout metric

Điều bất biến: không track nào vừa fit vừa chấm; holdout không được dùng để retune; final refit là model khác với evaluation model.

K-Means và GMM khác nhau thế nào

Cùng dataset và F9; K-Means dùng Robust, GMM baseline dùng Standard

K-Means — hard partition

centroid · SSE · mỗi track thuộc đúng một cụm

k-means++ · n_init=20 · seed 42

F9 · RobustScaler · không PCA · K=2

Hai persona rộng, gần như bất biến qua seed

0,5956

Silhouette trên development cohort (n = 3.000)

GMM — soft posterior

EM · likelihood · mỗi track có vector trách nhiệm

F9 · StandardScaler · no PCA · covariance diag/full

Hard label = argmax posterior; không phải xác suất genre

Full K=4: BIC 853.058 · confidence trung bình 0,9578

0,0547

Silhouette hard-label của GMM full K=4 (F9/Standard) trên eval cohort

Hai run khác scaler space (Robust vs Standard); không so trực tiếp silhouette xuyên space.

K-Means robust K=2 được chọn cho phân đoạn cứng; GMM full K=4 là comparator mềm.

Chọn K: validity, balance, stability

Không có K nào thắng mọi metric; quyết định là multi-criteria và được khóa trước holdout

K = 2 · được chọn

0,5956

silhouette · min share 19,55% · ARI 0,9997

K = 4

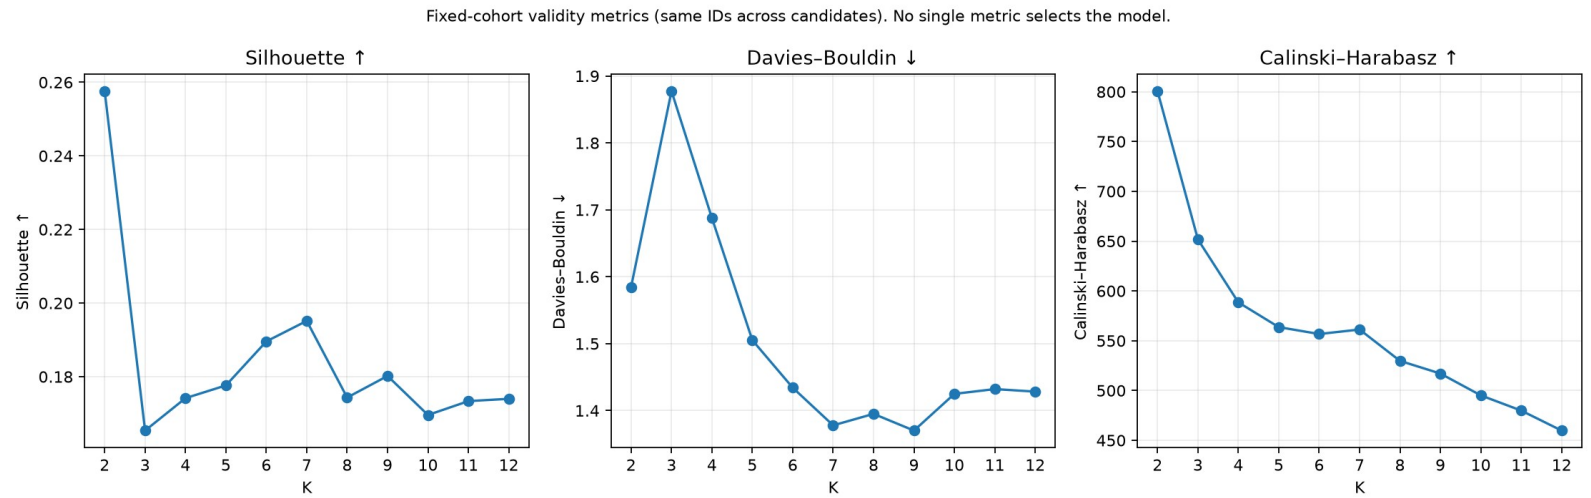
0,4884

silhouette · min share 1,02%

K = 6

0,3374

silhouette · min share 1,01% · ARI 0,9164



Vì sao K = 2?

Silhouette và CH cao nhất

Cụm nhỏ nhất vẫn 19,55% trên fit

Seed/bootstrap ARI 0,9997 / 0,9991

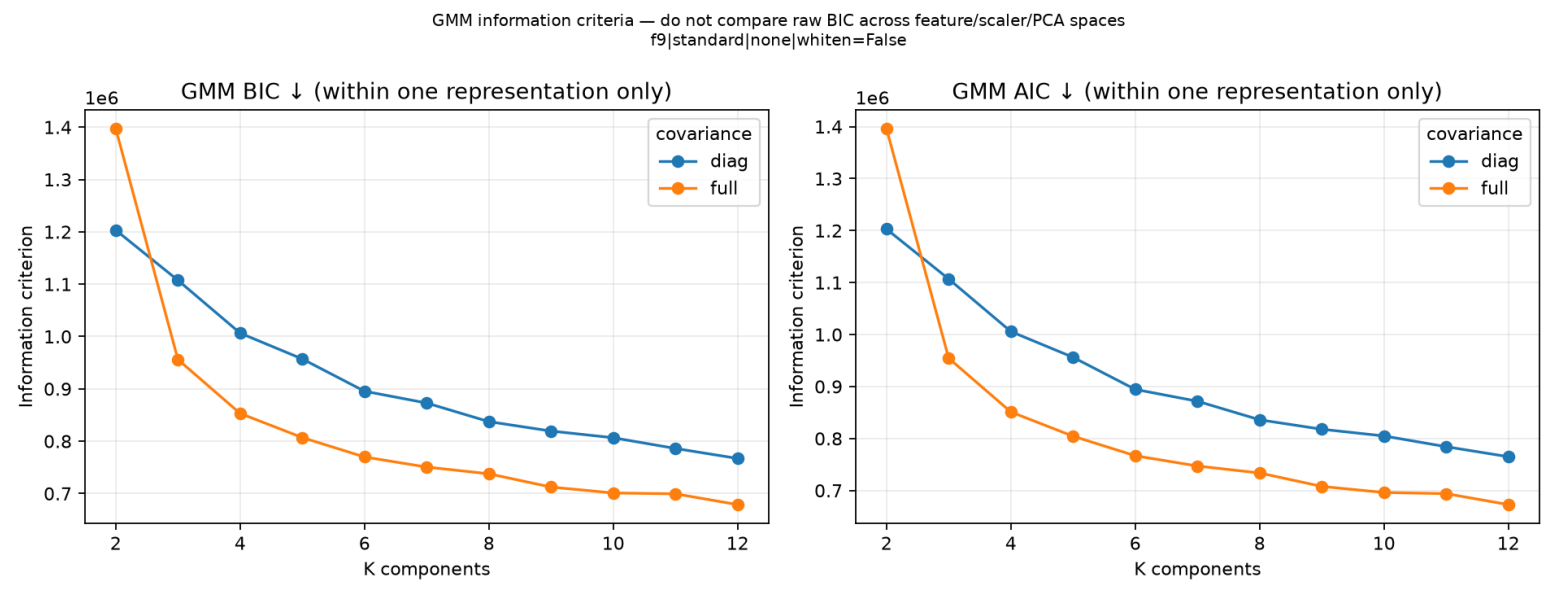
K=6 giàu profile hơn nhưng cụm ~1,1% và ARI 0,916

K=2 được khóa trước khi mở holdout

K-Means F9/Robust/no-PCA · eval cohort 3.000 track · không so silhouette xuyên representation

GMM & BIC: BIC không phải tiêu chí duy nhất

BIC giảm tới biên K=12 nhưng hard-label separation giảm theo



Đọc BIC đúng cách

BIC thấp nhất: K=12 full = 678.842

Silhouette hard-label K=12 = −0,0234

K=4 full: BIC 853.058 · silhouette 0,0547 · confidence 0,9578

0,33% eval có confidence < 0,5

Chỉ so BIC trong cùng representation/cohort

BIC thấp ≠ cụm tốt. BIC/AIC đo fit density có phạt complexity; GMM full K=4 (F9/Standard) đạt 0,0547, K-Means robust K=2 (F9/Robust) đạt 0,5956 — không so trực tiếp xuyên space.

GMM full K=4: mean posterior confidence 0,9578 · normalized entropy 0,0802 · hữu ích cho track biên

Ablations: scaler, feature set, PCA

24 dòng ablation · 15 fit mới + 9 tái dùng baseline · 0 lỗi

Scaler · K=2

Robust 0,5956

Standard 0,2576

None (E00) 0,5167

Robust giữ DB 0,6505 so với Standard 1,5848; E00 bị tempo/loudness chi phối.

Feature set · K=2

F9 0,2576 · DB 1,5848

F5 0,2980 · DB 1,3700

F5 compact hơn nhưng mất loudness, speechiness, instrumentalness, liveness — các feature tạo persona instrumental/speech. F9 được giữ làm primary.

PCA · K=6

no PCA 0,1896

PCA90 (7 comp) 0,2033

PCA95 (8 comp) 0,1938

PCA90 cải thiện nhẹ nhưng thêm representation và loadings gián tiếp; no-PCA được giữ cho final.

Không xếp hạng tuyệt đối xuyên space. Silhouette/DB/CH ở scaler, feature set và PCA space khác nhau không cùng thang đo; BIC chỉ so trong cùng representation/cohort.

Artifact: artifacts/ablations/{scaler,feature_set,pca}/20261027T0321*/ · metrics_by_variant.png

Nguồn: artifacts/final-report-tables/ablation_*.csv · REPORT_TABLES.md §4

Stability & one-time holdout

Cùng reference IDs, cùng metric; holdout chỉ mở sau khi model đã khóa

Stability — 3.000 reference IDs

Seed refits	Bootstrap	Pairwise
0,99969	**0,99907**	**0,99918**

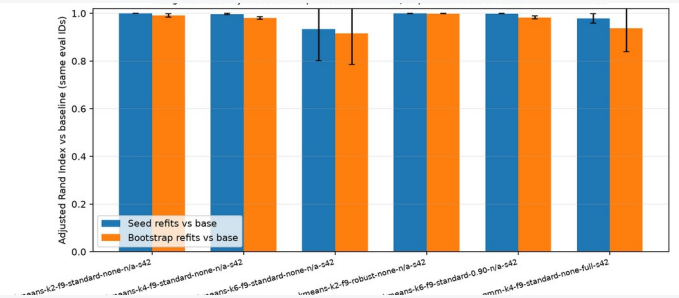
5 seed + 5 bootstrap · 60/60 refits thành công · ARI bất biến hoán vị nhãn

Finalist K-Means robust K=2 gần như bất biến qua seed và bootstrap; K=6 standard thấp hơn rõ rệt (0,9164 bootstrap).

One-time holdout — không refit

METRIC	HOLDOUT	DEV	Δ
Silhouette ↑	**0,5902**	0,5956	−0,0054
Davies–Bouldin ↓	**0,6593**	0,6505	+0,0088
Calinski–Harabasz ↑	**2964,07**	3240,62	−276,5

Chênh lệch nhỏ; đây là sanity check, không phải accuracy. Holdout không được dùng để chọn lại K/scaler/model.



Model khóa: K-Means F9 · Robust · no PCA · K=2 · seed 42

Evaluation run 20261027T032109Z_07fbb11b… · holdout run 20261027T032820Z_f7434a8c…

Holdout dùng đúng một lần; không retune; final refit là model identity riêng.

Nguồn: artifacts/runs/20261027T032241Z_ea0570dc_b202fa49_stability · artifacts/final-report-tables/holdout_metrics.csv

Profiles, case study & genre sanity

Profile thô + kiểm tra hậu nghiệm; genre không tham gia huấn luyện

CỤM 0 · 80,47%

72.211 track

Vocal/non-instrumental

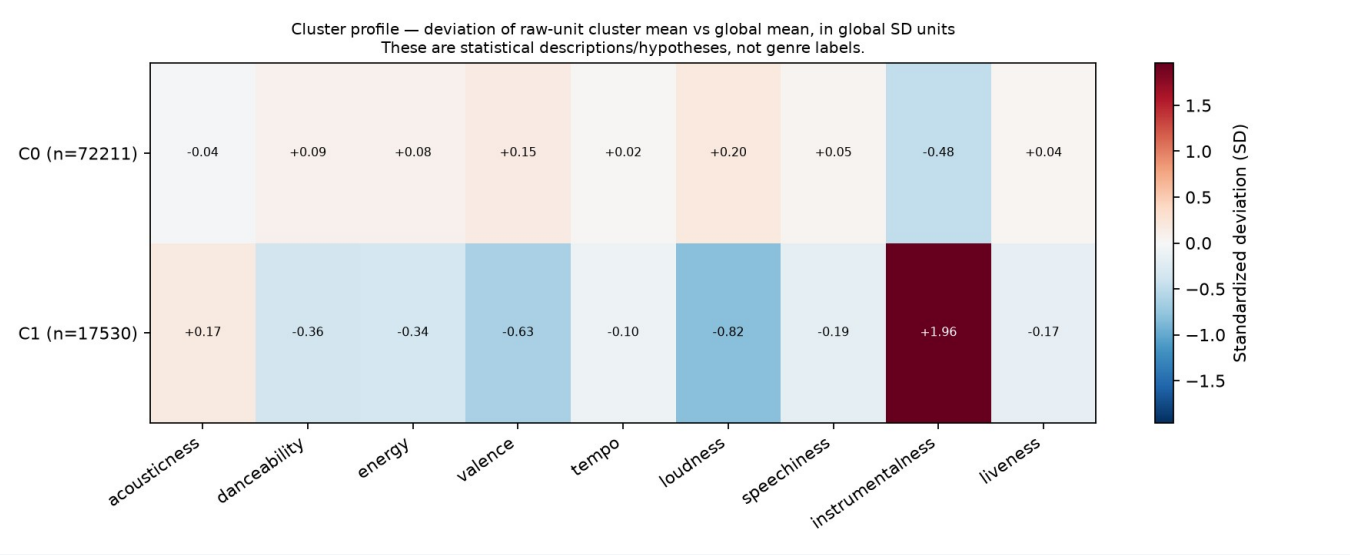
energy 0,688 · dance 0,584 · instr ~0

CỤM 1 · 19,53%

17.530 track

Instrumental/ambient

instrumentalness 0,858 · acousticness 0,149



Profile raw-unit (median) — acoustic hypothesis, không phải genre

Case study — track gần centroid

Cụm 0 · Aynalarımda — Stabil; Bedo
energy 0,749 · dance 0,614 · instrumentalness ~0

Cụm 0 · Re Re Bajarangi — Kailash Kher
energy 0,740 · dance 0,539 · instrumentalness 0

Cụm 1 · Letters – NTO Remix — KAS:ST; NTO
instrumentalness 0,806 · energy 0,560

Cụm 1 · CLOCK — Plaid
instrumentalness 0,822 · energy 0,522

GENRE SANITY — CHỈ HẬU NGHIỆM

0,0041
ARI so với genre

0,0817
NMI so với genre

73.442 track đơn thể loại; 16.299 track đa thể loại bị loại khỏi phép đo.

Cụm 0: pagode · reggae · reggaeton (~1,38% mỗi genre)

Cụm 1: study 5,20% · minimal-techno 5,03% · sleep 4,65%

Không dùng genre để chọn K/scaler/model.

Cụm là audio persona, không phải genre discovery. PCA2D/t-SNE chỉ để nhìn.

Kết luận & hạn chế

01 **Hai nhóm instrumental/vocal ổn định**

instrumental/ambient 19,53% và vocal/non-instrumental 80,47% trên 89.741 track.

02 **Holdout xác nhận cấu trúc**

Silhouette 0,5902 so với 0,5956 dev; stability ARI 0,9997 (reference IDs); không retune sau holdout.

03 **GMM mềm, không thay K-Means**

Posterior hữu ích cho track biên; hard-label silhouette 0,0547 (F9/Standard) so với 0,5956 (F9/Robust) — không so trực tiếp.

Genre không phải target: ARI 0,0041 · NMI 0,0817. Cụm là audio persona, không phải genre discovery.

HẠN CHẾ & CỔNG CON NGƯỜI

License pending: ODbL vs BSD vs Spotify provenance; raw CSV không public.

Snapshot 114.000 dòng / 114 genre; không đại diện thị trường.

K=2 rất rộng; K=6 giàu hơn nhưng kém ổn định và có cụm ~1,1%. K=2 chủ yếu do instrumentalness quyết định (97,3% between-SS; LOO ARI −0,05): phân đoạn instrumental/vocal, không phải đa biến cân bằng.

Không có user behavior hay causal claim.

Git remote, deploy và rehearsal là quyết định của con người.

Q&A · artifacts/INDEX.csv · artifacts/final-report-tables/REPORT_TABLES.md